

專題計畫報告

基於時空圖卷積神經網路與強化學習之智慧 建築環境預測與分析控制系統

專題成員(我們是升
大二的學生):

114501027 徐義豐

114501550 洪暉智

摘要

本專題規劃一套可在建築內部離線運作的智慧控制系統，應用於宿舍、大廳、走廊、樓梯間、交誼廳、健身房、地下停車場與地下室等公共空間。系統會持續蒐集照度、濕度、溫度、二氧化碳濃度、人流量、耗電量、時間與設備狀態，先預測各區域未來的環境變化，再決定燈光、窗簾、空調、除濕、新風系統、排風及循環扇的控制方式。

環境預測模型以時空圖卷積網路為基礎，將各建築區域視為節點，建立熱傳、空氣、採光與人流關係圖，為處理建築中特別的物理特性，採用 TCN-GCN-TCN 架構，並加入多尺度時間卷積、動態圖卷積、物理殘差與多任務輸出。控制端先以規則控制作為基準，再導入強化學習，並透過安全層限制不合理的設備命令。

系統預計採用 ZYNQ 架構，由 CPU/ARM 負責感測器通訊、資料前處理、強化學習決策與安全檢查，FPGA 則加速時間卷積、圖聚合及矩陣乘法等推論運算，抑或是依需求移植至 SBC 單板電腦。系統將以預測準確度、環境舒適度、能耗、推論延遲與功耗進行評估。

透過本方法，預期完成一套可離線蒐集建築環境資料、分析多區域節點關係、做出多空間控制決策、最佳預測未來環境，並利用強化學習即時控制設備的智慧建築原型系統，同時透過 CPU/ARM 與 FPGA 實現邊緣推論。

一、計畫背景與動機

社區大樓與校園建築的公共空間常採固定時間開關或人工控制。這種方式無法配合人流、戶外日照、季節、門窗狀態及不同區域用途，因此容易出現白天仍開燈、無人區域持續空調、濕度恢復正常後除濕機仍運轉，以及人員聚集時通風不足等問題。

我們列出了主要的參考變量：採光度、濕度、溫度、二氧化碳濃度、人流量、耗電量與時間，並將控制需求分成採光、濕度、溫度與二氧化碳四個模組。本計畫會以「先預測、再控制」的閉迴路系統為目標處理。

先預測的好處是系統不必等到環境已經有問題才處理。例如目前二氧化碳濃度仍可接受，但模型預測十五分鐘後會因人員聚集而快速上升，系統便可提前通風，避免之後必須全速運轉，同時提高舒適度、空氣品質與能源效率。

二、問題討論與計畫目標

2.1 問題討論

建築環境同時具有時間性與空間性。時間性是指溫度、濕度、二氧化碳與照度會隨時間累積或快速變化；空間性是指大廳、走廊、會議室、樓梯間與戶外會透過人流、門窗、空氣交換、熱傳與採光互相影響，這也是為何需要結合 GCN 與 TCN 來處理。因此，單一空間的規則控制無法完整描述整棟建築的變化。

本計畫把每個區域視為圖中的節點，把區域間的熱、空氣、光線與人員移動關係視為邊，再利用時間卷積處理歷史趨勢、圖卷積處理跨區域影響。模型預測未來環境後，再由強化學習或規則控制選擇設備動作(畢竟人因問題單由神經網路處理，可能沒那麼有效率)。

2.2 計畫目標

- 建立可離線運作的多區域感測與控制平台，不依賴外部雲端服務。
- 建立照度、溫度、濕度、二氧化碳、人流、耗電與設備狀態資料集作為資料收集標的。
- 分階段完成時空圖神經網路並優化算法。
- 同時預測各區域未來溫度、濕度、二氧化碳與照度。
- 完成規則控制、強化學習的部分會先將設備控制動作離散化，後續再作連續的。
- 加入安全規則層，避免極端決策。
- 完成 CPU/ARM 與 FPGA 分工的邊緣推論模形。
- 以預測準確度、舒適度、空氣品質、能耗及推論效能驗證系統。

三、需求與系統

3.1 需求對應

標的因子	在本系統中的角色	主要用途
採光度	狀態與預測目標	控制燈光亮度與窗簾開度
濕度	狀態與預測目標	控制除濕、空調與循環扇
溫度	狀態與預測目標	控制空調設定與循環扇
二氧化碳濃度	狀態與預測目標	控制新風、排風與循環扇
人流量	外生輸入與關係圖	預估熱負載、二氧化碳與照明需求
耗電量	回饋與評估指標	計算節能效果與強化學習獎勵

標的因子	在本系統中的角色	主要用途
時間	週期性輸入	區分時段、星期、季節與使用習慣

3.2 場域範圍

初期驗證以三至五個區域為主，例如戶外、大廳、走廊、會議室與樓梯間。模型與資料格式保留擴充能力，後續可增加地下停車場、地下室、交誼廳、健身房與公共倉儲空間。

本計畫控制公共空間的環境設備，不處理電梯、門禁、消防與緊急廣播等高風險系統。考量到消防與法規設備維持原有獨立控制，本系統不覆蓋其命令。

3.3 初步控制範圍

項目	原始需求中的初步範圍	本計畫使用方式
走廊照度	100~150 Lux	作為初始目標，部署前依場域量測調整
樓梯間照度	約 100 Lux	作為初始目標，保留安全最低照度
地下停車場照度	75~150 Lux	依時段與有人狀態動態調整
相對濕度	40~60% RH	作為舒適帶；超出時逐步增加除濕
室內溫度	22~26°C	作為初始舒適帶；依區域用途調整
二氧化碳	400~800 ppm 良好；1000 ppm 以上需注意	以場域安全規則與設備能力設定分級控制

四、整體系統架構

4.1 完整運作流程

感測資料 → 資料前處理 → 多關係動態 MR-STGCN(多尺度 TCN → 多關係動態 GCN → 多尺度 TCN) → 物理殘差 → 多任務環境預測 → RL 決策 → 安全規則 → 設備控制 → 感測回饋

系統每隔固定時間接收各區域的新資料。預測模型先推估未來環境；控制器再根據現在與未來狀態選擇設備動作；安全層修正不合理命令；設備執行後，新的感測結果再回到模型。

4.2 系統分層

層級	主要功能	實作內容
感測層	取得建築狀態	照度、溫濕度、二氧化碳、人流、耗電、門窗與設備狀態
資料層	整理可用資料	時間同步、補值、去除異常、標準化、建立滑動時間窗
預測層	預測未來環境	多尺度 TCN、GCN、物理殘差、多任務輸出
決策層	選擇控制動作	規則控制、DQN、PPO 或 SAC
安全層	限制危險動作	操作範圍、最短啟停時間、通風下限、故障處理
執行層	控制實體設備	燈光、窗簾、空調、除濕、新風、排風與循環扇
監控層	呈現與記錄結果	離線儀表板、事件紀錄、耗電統計

五、感測、設備與資料設計

5.1 初期感測器配置

量測項目	元件範例(可能在驗證系統時使用)	資料用途
照度	BH1750	室內採光與燈光控制
溫度、濕度	DHT22	熱濕環境預測
人體存在／ 人流	PIR、攝影機	有人狀態與人流圖
二氧化碳	SCD41	空氣品質預測
耗電量	PZEM-004T	節能評估與獎勵函數
時間	RTC 或系統時鐘	時段與週期特徵
門窗／設備 狀態	數位輸入或控制 回讀	更新動態鄰接矩陣
戶外環境	戶外照度、溫濕 度	提供外部擾動資訊

5.2 控制設備

環境目標	主要設備	控制量
照度	可調光燈具、窗簾	開關、亮度百分比、窗簾開度
濕度	除濕機、空調、循環扇	啟停、功率、風速與設定值
溫度	空調、循環扇	啟停、設定溫度、風速
二氧化碳	新風、排風、機械換氣、循環扇	換氣量、風速與啟停

六、技術簡介

6.1 概述

上面有對此做介紹了，這邊簡單描述下。

系統會持續接收各區域的感測資料，例如：

大廳：溫度 27.5°C 濕度 68% CO₂ 1050 ppm 照度 180 Lux 人數 18 人

走廊：溫度 26.8°C 濕度 65% CO₂ 780 ppm 照度 90 Lux 人數 4 人

所以除了判斷目前狀況有什麼問題以外，還要對未來的情況做預測。

但是不能只看單一區域，不同區域會互相影響，比如：假設走廊目前只有兩個人，CO₂ 也不高，只看走廊自己的資料，可能得到：

目前人少，CO₂ 不高 → 未來應該也不會太高，

但此時大廳有 30 個人，而且即將走向走廊，此時就會因為大量人員進入走廊導致 CO₂ 飆升，因此，預測走廊的狀態時，不能只看走廊自己，也要看：大廳、相鄰房間、樓梯間、戶外、空調與通風設備。

對於處理這種非歐幾里得，又包含時間序列的結構，我們會使用 GCN 和 TCN 的混合架構。

雖然上面有提到 STGCN，但這個模型使用的架構跟大部分文獻上用於處理骨架的 STGCN 不太一樣，我們覺得可能比較類似[2]的架構，但仍不太一樣。基本流程為：

第一個時間卷積：分析每個區域最近的環境趨勢

圖卷積：讓相鄰區域交換資訊

第二個時間卷積：分析區域影響發生後的後續趨勢

這樣就可以做與預測分析了，控制決策可以交給 RL(強化學習)。

Temporal Conv → Graph Conv → Temporal Conv

以下暫以 MR-STGCN 來代稱我們的方案

6.2 技術想法

這裡是關於技術上的一些方案，這邊會以重點形式描述，但並非空穴來風，我們詳細的討論文件可以參考: <https://github.com/Yifeng-XuMaker/STGCN>

第一，一般來說，GCN 的通式為:

$$H^{(l+1)} = \sigma \left(\hat{A} H^{(l)} W^{(l)} \right)$$

不過，本專題需要處理熱流圖，CO2 圖，採光圖，人流圖等等，所以每個

圖會有自己的鄰接和權重矩陣，所以融合下來就會變成:

$$H' = \sigma \left[H W_0 + \sum_{r \in R} \alpha_r \hat{A}_r H W_r \right]$$

這樣做的好處是可以知道每種因子重視什麼圖，比如 CO₂ 主要重視空氣圖與人流圖.....。

不過每張圖可能還需要引入一個獨立的權重，因為這四張圖不可能在任何情況下都同樣重要，它可能是定值，也可能會另外引入演算法或小型神經網路計算。

第二，我們會加入動態鄰接矩陣。門窗、風扇及空調等設備狀態會改變區域間的影響程度，因此使用設備閘門 $G_r(t)$ 即時調整邊權重。另外，因為一般的拓譜可能會忽略一些隱藏的資訊，比如兩個房間不相鄰，但共用同一套空調，所以溫度高度相關，這時就要讓模型學習一個新的鄰接矩陣，最後就會變成:

$$A_r^{\text{final}}(t) = A_r^{\text{physical}} \odot G_r(t) + \lambda_r A_r^{\text{learned}}$$

其中， λ_r 控制學習的影響程度。

第三，引入物理殘差，神經網路本身可能產生不符常理的預測，因此在某些模型中(比如 CO₂)，加入簡單的物理模型，讓神經網路只學習修正量:

$$\hat{Y} = Y_{\text{physics}} + \Delta Y_{\text{neura}}$$

第四，多任務輸出，意思是模型需要同時處理多個環境變數，而不是每一個變數都建立獨立模型，比如溫度、濕度、CO2、照度會更用一個 STGCN 骨幹與時空特徵，最後在分成四個輸出頭產生不同預測結果。輸出頭是一小段專用的小型神經網路，處理邏輯就是假設有一個時空特徵 H_{shared} ，則溫度與濕度就會變成：

$$\hat{Y}_T = f_T(H_{shared}) \quad \hat{Y}_H = f_H(H_{shared})$$

第五，加入控制動作，這樣做是為了讓模型處理控制設備後的環境變化，設 s 為環境狀態， u 為空調、風扇、燈光、窗簾等動作，即：

$$\hat{s}_{t+1:t+H} = f_{\theta}(s_{t-T+1:t}, u_{t:t+H-1})$$

模型就可以回答採取這組設備動作後，未來的環境會如何變化？

最後，流程會變成：

感測資料 → 資料前處理 → 多尺度 TCN → 多關係動態 MR-STGCN → 多尺度 TCN → 物理殘差 → 多任務環境預測 → RL 決策 → 安全規則 → 設備控制 → 感測回饋

6.3 膨脹卷積

建築變數的速度不同。照度與人流可能快速改變，二氧化碳會在數分鐘內累積，溫度與濕度則具有較慢的慣性。因此目前想法是同時使用 dilation 為 1、2、4(或其他大小) 的時間卷積分支，再融合短期、中期與較長期特徵。

$$R = 1 + (K - 1) \sum d_l$$

其中 R 為感受野， K 為卷積核大小， d_l 為第 l 層的 dilation。此公式可估算模型在輸出一個時間點時，最多能利用多少歷史資料。

6.4 圖設計

關係圖	邊的意義	主要預測目標
熱傳圖	牆面、門窗、空調與相鄰區域造成的熱交換	溫度、濕度
空氣圖	新風、排風、門窗與風向造成的空氣交換	二氧化碳、溫濕度
採光圖	戶外光線、窗戶方向、遮蔽物與窗簾影響	照度
人流圖(有向)	人員由一區移動至另一區的方向與強度	人數、二氧化碳、熱負載與照明需求

6.5 展望：專家混合模型（Mixture of Experts, MoE）(重要)

為降低模型運算量並提升不同環境情境下的預測能力，之後會視情況在原架構中導入 Mixture of Experts (MoE) 概念。MoE 的核心思想為建立多個專門負責不同任務的 Expert（專家模型），再由一個 Gate Network（門控網路）根據目前環境狀態，動態選擇最適合的 Expert 參與推論，而非每次皆啟動完整模型。

由於本專題同時處理熱傳、空氣流動、採光及人流等不同物理關係，因此可分別建立對應的 Graph Expert，各自學習不同類型的時空特徵。例如：

Heat Expert：學習熱傳與溫度變化。

Air Expert：學習空氣流動與 CO₂ 擴散。

Light Expert：學習採光與照度分布。

Crowd Expert：學習人流移動與區域使用情形。

而各 Gate Network 以目前的環境狀態（如時間、設備狀態、人流及室外環境）作為輸入，計算各 Expert 的重要程度。為進一步降低推論成本，預計會參採 Sparse MoE 機制，每次僅啟動權重最高的前幾個 Expert，而非全部 Expert 同時運算。這種方法可使模型依據不同環境情境，自動選擇較相關的物理關係進行推論，例如白天提高採光 Expert 的比重，夜間則增加空氣流動與人流 Expert 的影響，其可提升模型效能、降低運算量，並增加模型的擴充性。

但我們認為此架構會讓 6.2 中的架構有點衝突，因此預計會先完成原有設計，在插入這個概念，尤其是輸出任務的部分必須交由多任務輸出頭負責，而 MoE 主要是在 GCN 做完後，用上面提到的四個 Expert 決策(Gate 選擇)，這樣第二個 TCN 就可以接收到已經過濾、加權、融合好的特徵。最後會設計消融實驗和 FLOPs 等等的一系列實驗驗證此方法對模型的效益。

八、四類環境控制模組

8.1 採光控制

採光模組使用區域、室內照度、戶外日照、時間、人流、歷史使用狀況、燈光狀態與窗簾狀態，預測未來照度。控制器優先利用自然光，再補足人工照明；無人區域可降低亮度，但樓梯與安全通道仍保留最低照度。所以流程大致為：

室內／戶外照度＋時間＋人流＋燈光／窗簾狀態 → 照度預測 → 燈光亮度與窗簾控制

8.2 濕度控制

濕度模組使用區域濕度、溫度、人流、室外濕度、歷史變化與除濕設備狀態。控制順序以避免過度耗電為原則，可先使用循環扇改善混合，再視濕度趨勢啟動除濕或空調除濕。所以流程大致為：

濕度＋溫度＋人流＋戶外濕度＋設備狀態 → 濕度預測 → 除濕功率、空調與循環扇控制

8.3 溫度控制

溫度模組使用室內外溫濕度、人流、日照、時間、歷史使用狀況及空調狀態。模型不只判斷現在是否偏熱，也預測人流增加、戶外溫度與日照造成的後續熱負載。所以流程大致為：

室內外溫濕度＋人流＋日照＋空調狀態 → 溫度預測 → 空調設定溫度與循環扇控制

8.4 二氧化碳控制

二氧化碳模組使用目前濃度、人數、人流方向、門窗、新風、排風與歷史濃度。主要控制設備為新風、排風或機械換氣，循環扇只協助空氣混合。系統在預測濃度即將超過門檻時提前通風，而不是等到超標後才反應。所以流程大致為：

CO₂＋人數／人流＋門窗＋通風設備狀態 → CO₂ 預測 → 新風、排風與循環扇控制

九、強化學習控制策略

9.1 強化學習的角色

MR-STGCN 負責回答「未來可能發生什麼」，強化學習負責回答「現在應該做什麼」。強化學習的決策目標不是只讓當下數值最好，而是兼顧未來舒適度、空氣品質、能源消耗與設備穩定性。不過，強化學習不直接在真實建築中進行初期探索，而是利用歷史資料、簡化物理模型及神經網路建立模擬環境，概念大概是目前狀態 → RL 選擇動作 → 模擬環境計算下一狀態 → 計算獎勵 → 更新控制策略。另外 RL 的決策要先機過安全機制層，避免發生短暫的極端甚至致人於死地的判斷。

9.2 狀態、動作與獎勵

元素	定義	例子
狀態 s_t	目前環境、未來預測、人數、設備狀態、時間資訊	溫濕度、CO ₂ 、照度、未來 15 分鐘預測
動作 a_t	設備控制命令	空調設定、新風比例、風速、除濕功率、燈光、窗簾
獎勵 r_t	舒適度、空氣品質、能耗與切換懲罰的加權結果	環境改善且耗能合理時獎勵較高
環境	真實建築或訓練用模擬器	物理模型 + MR-STGCN

十、邊緣運算與 FPGA 加速(或 SBC)與設備預算需求

10.1 分工

運算平台	主要工作
CPU/ARM	感測器通訊、資料庫、資料前處理、動態鄰接矩陣、強化學習、安全規則、設備命令與儀表板
FPGA	TCN 卷積、GLU 或啟用函數、圖聚合、特徵矩陣乘法、關係融合與多任務輸出層

以上是目前想法，在設備上會需要：

PYNQ-Z2 與周邊設備(或者其他 7020 以上規格之 ZYNQ 系統) 約 10000 元

NVIDIA Jetson Orin™ Nano Developer Super Kit(或 Raspberry Pi 5 8GB) 約 15000 元

模型會先在 SBC(單板電腦)上驗證，確認想法後再移植，CPU/ARM 的部分也會直接移植到 ZYNQ 系統上，但之後也有可能視情況將部分功能留在 SBC 上，抑或是在 SBC 上處理完整的專題。

十一、系統實作步驟與時程

步驟	工作內容
需求與場域建模	確認區域、感測器、設備、採樣週期與控制權限。
資料蒐集平台	完成感測器通訊、時間同步、資料庫與離線儀表板。

步驟	工作內容
規則控制基準	依原始需求的舒適範圍建立可解釋的基準控制。
單變量預測基準	先以簡單線性模型、MLP 或 TCN 預測各環境量。
基礎 STGCN 試驗	建立固定單圖的時間—空間—時間模型。
MR-STGCN	加入多關係圖、動態邊、多尺度時間卷積與多任務輸出。
物理殘差與動作條件	加入二氧化碳、熱濕簡化模型及設備動作資料。
強化學習	依序比較規則控制、DQN、PPO 與 SAC。
安全與影子模式	限制動作並在真實資料上先只產生建議。
FPGA 加速、MoE	完成量化、硬體推論與 CPU/FPGA 整合，測試 MoE 架構。
整合測試	長時間運轉、斷線、異常值、設備失效與回退測試。

此專題是一年的計畫，我們大概抓 10 個月，留一些緩衝。

工作項目	1	2	3	4	5	6	7	8	9	10
需求分析與場域建模	■	■								
感測器與資料平台	■	■	■							
資料蒐集與清理		■	■	■	■	■	■	■	■	■
規則控制與簡單基準			■	■						
基礎 STGCN 試驗			■	■	■					
MR-STGCN				■	■	■				
物理殘差與動作模型					■	■	■			
DQN/PPO/SAC						■	■	■		
FPGA 量化與推論							■	■	■	
MoE 架構測試與實驗								■	■	
整合、影子測試								■	■	■

十二、後續評估方法

12.1 預測模型評估

評估面向	試驗方式
預測誤差	MAE、RMSE、必要時使用 MAPE；四個目標分別計算
時間長度	比較 5、10、15 分鐘或不同 H 的預測結果
基準模型	歷史平均、線性模型、MLP、TCN、固定圖 STGCN
消融實驗	移除多關係圖、動態邊、多尺度 TCN、物理殘差、MoE 或多任務輸出
泛化能力	不同時段、不同星期、不同季節與不同區域
不確定度	分析人流突增、設備切換與感測器缺失時的誤差

12.2 控制效果評估

指標	意義
舒適範圍達成率	溫度與濕度位於目標範圍的時間比例
CO ₂ 超標時間	濃度超過控制門檻的累積時間與峰值
照度達成率	有使用需求時照度符合目標的比例
能源消耗	總耗電量及各設備耗電量
設備切換次數	衡量控制是否過度震盪
總獎勵	綜合環境品質、能耗與設備穩定性

12.3 邊緣推論評估

項目	比較方式
推論延遲	CPU 浮點、CPU INT8 與 FPGA INT8／定點
吞吐量	每秒可處理的樣本數或區域數
模型大小	權重記憶體與中間特徵記憶體
功耗與能效	每次推論能量或每瓦吞吐量
FLOPs	不同架構需要的總運算量

項目	比較方式
量化誤差	量化前後的預測誤差差異
平均運算量	條件路由或事件觸發下的實際啟動比例

十三、預期成果與專題目標

13.1 預期成果

- 一套可離線運作的多區域感測、預測與控制原型。
- 包含溫度、濕度、二氧化碳、照度、人流、耗電與設備狀態的資料集。
- MR-STGCN 模型及完整訓練流程。
- 規則控制、DQN、PPO 或 SAC 的控制比較結果。
- 安全規則層、異常偵測與故障回退機制。
- CPU／ARM 與 FPGA 協同推論展示。
- 可顯示環境趨勢、預測、設備命令與耗電量。
- 專題報告、系統操作文件、實驗紀錄與展示系統。

13.2 專題目標

- 以建築區域圖同時描述時間與跨區域影響，而非只看單一感測值。
- 將熱傳、空氣、採光與人流分成多張具有物理意義的關係圖。
- 依門窗與設備狀態更新邊權重，處理建築關係隨時間改變的問題。
- 以物理模型提供基本預測，神經網路負責修正，降低不合理結果。
- 同一共享模型同時預測四種環境量，減少重複運算。
- 把未來預測加入強化學習狀態，使控制器能提前處理問題。
- 以量化、MoE、稀疏運算與條件式計算(視情況加入)降低邊緣推論成本。

十四、風險、限制與替代方案

風險或限制	可能影響	替代方案
資料量不足	深度模型過擬合	先使用規則、線性模型與小型 TCN；延長蒐集時間
設備控制紀錄不完整	無法學習動作效果	先以物理模型與規則模擬，補建設備回讀

風險或限制	可能影響	替代方案
攝影人流辨識不穩	人流圖誤差	以 PIR、門口計數或匿名化人數作備援
感測器漂移或斷線	預測與控制失真	定期校正、冗餘感測、品質旗標與回退規則
強化學習模擬不準	部署後動作失效	影子模式、限權部署、保守策略與人工審核
FPGA 資源不足	完整模型無法放入	縮小通道、INT8、時間複用，或只加速 TCN／矩陣乘法
多任務互相干擾	部分目標誤差上升	使用獨立輸出頭、任務權重或拆成熱濕／空氣／採光分支
法規或設備權限制	無法直接控制實體設備	以模擬器或低風險設備完成驗證

參考文獻

- [1] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine, “Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor,” arXiv:1801.01290, 2018.
- [2] B. Yu, H. Yin, and Z. Zhu, “Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting,” arXiv:1709.04875, 2017; IJCAI, 2018.
- [3] T. N. Kipf and M. Welling, “Semi-Supervised Classification with Graph Convolutional Networks,” ICLR, 2017.
- [4] S. Bai, J. Z. Kolter, and V. Koltun, “An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling,” arXiv:1803.01271, 2018.
- [5] J. Schulman et al., “Proximal Policy Optimization Algorithms,” arXiv:1707.06347, 2017.