

本檔案僅為討論紀錄，可能並不嚴謹

控制邏輯如下

感測資料 → 資料前處理 → 多尺度 TCN → 多關係動態 MR-STGCN →
多尺度 TCN → 物理殘差 → 多任務環境預測 → RL 決策 → 安全規則
→ 設備控制 → 感測回饋

接下來是相關的東西

系統會持續接收各區域的感測資料，例如：

大廳：溫度 27.5°C 濕度 68% CO₂ 1050 ppm 照度 180 Lux 人數 18 人

走廊：溫度 26.8°C 濕度 65% CO₂ 780 ppm 照度 90 Lux 人數 4 人

除了判斷目前狀況有什麼問題以外，還要對未來的情況做預測。

例如：

目前大廳 CO₂：1050 ppm

模型預測：

5 分鐘後：1120 ppm

10 分鐘後：1210 ppm

15 分鐘後：1300 ppm

系統就可以在 CO₂ 嚴重超標前，提早啟動通風設備。

但是不能只看單一區域，不同區域會互相影響，比如：假設走廊目前只有兩個人，CO₂ 也不高，只看走廊自己的資料，可能得到：

目前人少，CO₂ 不高 → 未來應該也不會太高，

但此時大廳有 30 個人，而且即將走向走廊，此時就會因為大量人員進入走廊導致 CO₂ 飆升，因此，預測走廊的狀態時，不能只看走廊自己，也要看：大廳、相鄰房間、樓梯間、戶外、空調與通風設備。

所以需要使用 GCN(圖卷積神經網路)

1. 基本架構

圖卷積的圖指的是非歐幾里德結構的圖，即

$$G = (V, E)$$

G 指的是節點，E 是邊，長得很像分子結構那樣，假設

$V = \{\text{戶外、大廳、走廊、會議室、樓梯間}\}$

$E = \{\text{戶外} \leftrightarrow \text{大廳}, \text{大廳} \leftrightarrow \text{走廊}, \text{走廊} \leftrightarrow \text{會議室}, \text{走廊} \leftrightarrow \text{樓梯間}\}$

*E 不一定是雙向

每個節點都會有很多特徵 x ，比如：

$x_{\text{大廳}} = [27.5, 68, 1050, 180, 18] = [\text{溫度}, \text{濕度}, \text{CO}_2, \text{照度}, \text{人數}]$

假設共有三個區域：大廳、走廊、會議室

每個區域有五種特徵，那麼某一時間點的資料可以寫成：

$$X_t = \begin{bmatrix} 27.5 & 68 & 1050 & 180 & 18 \\ 26.8 & 65 & 780 & 90 & 4 \\ 26.2 & 63 & 850 & 320 & 8 \end{bmatrix}$$

此時 $N = 3$ ， $F = 5$ ，即

$$X_t \in \mathbb{R}^{3 \times 5}$$

好那問題來了，剛有說要接收歷史資訊對未來情況做預測，所以會有時間序列，因此 GCN 是不夠的，必須導入 TCN(時間卷積網絡)，意思是神經網路會需要看一份歷史資料，那輸入就會變成：

$$X \in \mathbb{R}^{T \times N \times F}$$

T 是取多少時間點。

那要怎麼把 GCN 和 TCN 兜在一起？可以引入時空圖卷積網路 STGCN，但本專題要用的 STGCN 跟一般用來處理骨架的 STGCN 模型比較不一樣。

方法是：

TCN：最近怎麼變？

↓

GCN：這些變化如何影響其他區域？

↓

TCN：影響發生後，接下來怎麼變？ 可以想成

$$\text{Temporal Conv} \rightarrow \text{Graph Conv} \rightarrow \text{Temporal Conv}$$

這種結構，比如：

第一個時間卷積：分析每個區域最近的環境趨勢

圖卷積：讓相鄰區域交換資訊

第二個時間卷積：分析區域影響發生後的後續趨勢

這樣就可以做與預測分析了，控制決策可以交給 RL(強化學習)。

2. 原理

打字很累...這裡盡量長話短說。

1. 鄰接矩陣 A、特徵矩陣 X、度矩陣 D 與正規化

鄰接矩陣就是描述兩個節點有沒有連線 1 代表有，0 代表沒有，比如 A_{ij} 就代表節點 i 和節點 j 的關係。所以如果兩個節點的邊是雙向的，A 就會是對稱矩陣。

特徵矩陣就是上面的 X_t 。

把它們乘起來就是 AX ，意義是讓節點把鄰居的特徵收集起來。

但在這個專題中，通常 A 需要考慮自己原本的狀態，因此會讓 $i=j$ 的時候是 1，即：

$$\tilde{A} = A + I$$

以上說明了，節點鄰居很多的話數值就會超大，比如走廊可能有超多鄰居，但這不代表這個節點很重要，而且可能會有尺度炸開的問題，所以要做正規化。

度矩陣就是描述一個節點有多少連線，然後把數量丟到矩陣對角線，比如：

$$\tilde{D} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

就代表第一個節點有 2 個連線，第二有 3 個，第三有 2 個。

*這裡的連線包含自己連自己，跟 A 一樣。

而正規化公式為(推導略)：

$$\hat{A} = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$$

2. 權重矩陣 W

W 描述收到資訊後，節點特徵要如何組合與轉換，比如：

$$X = [28, 1000] = [\text{溫度}, \text{CO}_2]$$

但神經網路需要更其他奇怪的特徵，比如熱負載，空氣品質負載，則設

$$W = \begin{bmatrix} 0.8 & 0.1 \\ 0.2 & 0.9 \end{bmatrix}$$

$$XW = [222.4, 902.8]$$

意義是把原始資料轉成系統需要的數值表示，當然其實初始值要標準化(就高中數學那個標準化)，不然 CO2 太高了。

那 W 的值是哪來的?初值其實是亂設的，後面模型會自己訓練 W

首先要把輸入送進模型(Forward pass)，得預測參數

$$\hat{Y} = f_{\theta}(X, A)$$

其中 θ 代表所有可學習參數，例如 W，f 就是 GCN 計算(見 3)

對模型預測參數計算誤差(Y 是真實值)(損失函數計算方法略)

$$\mathcal{L}(Y, \hat{Y})$$

利用 Backpropagation 計算梯度

$$\frac{\partial \mathcal{L}}{\partial W}$$

最後更新 W(η 是學習率，即調整的幅度)

$$W_{\text{new}} = W_{\text{old}} - \eta \frac{\partial \mathcal{L}}{\partial W}$$

3. GCN 圖卷積神經網路

綜合以上，GCN 的通式就是

$$H^{(l+1)} = \sigma \left(\hat{A} H^{(l)} W^{(l)} \right)$$

H 就是第 l 層的輸入特徵， σ 是啟用函數，比如 ReLU(ReLU(x) = max(0,x))，詳見聿廣的 final project。一層 GCN 可以看鄰居，兩層可以看鄰居的鄰居……，訓練會變成：輸入資料 → 預測 → 比較真實答案 → 算損失 → 調整 W → 再預測。

4.TCN 時間卷積網路

TCN 就是處理一地點的時間序列，例如，大廳最近六個時間點的 CO₂：

$$[600, 650, 720, 810, 930, 1080]$$

TCN 會用卷積核去掃描這個陣列(要先做 padding)，跟 CNN 的差別在 TCN 的核是一維的(詳見聿廣的 final project)，核會算出

$$y_t = w_1 x_{t-2} + w_2 x_{t-1} + w_3 x_t + b$$

卷積核的數值決定它想要從這個陣列得到什麼資訊，另外這是一個因果卷積，就是你不能預測未來，所以只能在左側 padding。*TCN 是並行卷積，跟 RNN 不一樣!當然，可以一次輸入好幾個批次的資料 B，輸入就會是：

$$X \in \mathbb{R}^{B \times T \times N \times F}$$

5.感受野

感受野就是模型能看到多大範圍的資料，比如卷積核大小是 3，那感受野就是 3，啊如果我想看到更大範圍的資料怎麼辦?卷積核太大的話運算量會很大，那就可以使用膨脹卷積(Dilation)。

通常 $d=1$ 時，會看到 但當 $d=2$ 時，會變成



感受野 R 的公式為(L 是層數 K 是核的大小)

$$R = 1 + L(K - 1)$$

而典型 TCN 會讓 dilation 逐層增加，這時感受野 R

$$R = 1 + (K - 1)d$$

d 疊加時將所有 d 相加即可。


藉由感受野 R 的伸縮，一個序列可以訂定不同尺度的 R 來處理不同的問題。所以 TCN 的邏輯是：

輸入時間序列 → 因果卷積 → 膨脹卷積 → 啟用函數 → 正規化 → Dropout(神經元開關) → 殘差連接 → 輸出時間特徵

6.殘差連接

TCN 可以使用殘差結構，意思是模型不必完全重新產生輸出，而是學習在原本輸入上，應該增加或修正什麼。

比如輸入 X ----|



7.GLU(Gated Linear Unit)

TCN 輸出: $[P, Q]$ ，其中 P 是候選時間特徵， Q 是控制閘門，算出

$Y = P \odot \sigma(Q)$ ， σ 控制 Q 介於 0 和 1， $\odot$ 就是逐元素相乘，這樣 Y 就能讓模型看出每個時間特徵的保留或阻擋程度。

8.STGCN 時空圖卷積神經網路

上面有說過控制邏輯如下:

$$\text{Temporal Conv} \rightarrow \text{Graph Conv} \rightarrow \text{Temporal Conv}$$

這個流程可表示為:

$$V^{l+1} = \Gamma_1^l *_{\mathcal{T}} \text{ReLU}(\Theta^l *_{\mathcal{G}} (\Gamma_0^l *_{\mathcal{T}} V^l))$$

這個遞迴關係式中的符號意義如下:

$\Gamma_0 *_{\mathcal{T}} V$: 第一次時間卷積。

$\Theta *_{\mathcal{G}}$: 圖卷積。

ReLU: 加入非線性。

$\Gamma_1 *_{\mathcal{T}}$: 第二次時間卷積。

STGCN 的輸入資料為:

$$X \in \mathbb{R}^{B \times T \times N \times F}$$

其中，批次大小為 B ，歷史時間點數為 T ，區域數量為 N ，每區特徵數為 F 。

第一次時間卷積針對每個節點自己的歷史資料運算，即

$$H_T = \text{TemporalConv}(X)$$

然後經過 GLU 處理，完成後，每個節點已經具有時間趨勢特徵。

接著做圖卷積，目的是讓不同節點交換資訊，方法如 3，但也可使用頻譜圖卷積，並做切比雪夫多項式近似:

$$g_\theta *_G H = \sum_{k=0}^{K_s-1} T_k(\tilde{L}) H \Theta_k$$

可能會以此做初步驗證，但這個專案可能不太適合，因為頻譜圖卷積不適合計算有向圖或結構不固定，鄰接矩陣不穩定的圖。

第二次時間卷積處理的是，加入鄰近區域影響後，這些環境狀態接下來如何發展？方法如上。

9. MR-STGCN 多關係時空圖卷積網路

這個專題會對既有的基礎 STGCN 架構做改良，名子是我亂取的。

首先，本專題需要處理熱流圖，CO2 圖，採光圖，人流圖等等，所以每個圖會有自己的鄰接和權重矩陣，所以融合下來就會變成

$$H' = \sigma \left[HW_0 + \sum_{r \in R} \alpha_r \hat{A}_r HW_r \right]$$

這樣做的好處是可以知道每種因子重視什麼圖，比如 CO₂ 主要重視空氣圖與人流圖……。

第二個修改點是，建築中的區域關係可能會隨設備變化，比如兩個節點中，風扇和門的開關就會影響空氣交換的程度，因此可建立一動態的鄰接矩陣:

$$A_r^{\text{dynamic}}(t) = A_r^{\text{physical}} \odot G_r(t)$$

其中，G 是處理設備狀態的因子，介於 1 和 0 之間，可影響實際算出來的權重。比如說原本 0.6，那設備影響造成特徵減弱，那可能 $G = 0.8$ ，實際的值就會變 0.48。另外，因為一般的拓譜可能會忽略一些隱藏的資訊，比如兩個房間不相鄰，但共用同一套空調，所以溫度高度相關，這時就要讓模型學習一個新的鄰接矩陣，最後變成

$$A_r^{\text{final}}(t) = A_r^{\text{physical}} \odot G_r(t) + \lambda_r A_r^{\text{learned}}$$

其中， λ_r 控制學習的影響程度。

第三個修正是此專題會使用多個膨脹卷積，比如我分別設 $d=1$ ， $d=2$ 和 $d=4$ ，這樣我就可以分別看出不同的時間尺度下的影響， $d=1$ ：短期快速變化； $d=2$ ：中期趨勢； $d=4$ ：較長期累積變化。

第四個是此專案需要加上人流圖，因為人流圖是有向圖，也就是他是邊(E)是有方向性的。

第五個是加入關係注意力的機制，一開始有提到，這個模型需要多張圖，但這四張圖不可能在任何情況下都同樣重要，原本是

$$H' = M_{\text{thermal}} + M_{\text{air}} + M_{\text{light}} + M_{\text{human}}$$

其中：

$$M_r = \hat{A}_r H W_r$$

但我們要引入一個權重 α ，讓它調整每張圖的重要程度，它可能是定值，也可能會另外引入演算法或小型神經網路，透過 softmax 算出。

$$H'_i = \sum_r \alpha_{i,r} M_{i,r}$$

第六個是引入物理殘差，神經網路本身可能產生不符常理的預測，因此在某些模型中，加入簡單的物理模型，讓神經網路只學習修正量：

$$\hat{Y} = Y_{\text{physics}} + \Delta Y_{\text{neura}}$$

比如 CO2 先引入以下模型

$$C_{t+1}^{\text{physics}} = C_t + \frac{\Delta t}{V} [q_p N_t - q_v (C_t - C_{\text{out}})]$$

神經網路再修正氣流不均、門縫、感測器位置等難以建模的因素。

第七個是多任務輸出，意思是模型需要同時處理多個環境變數，而不是每一個變數都建立獨立模型，比如溫度、濕度、CO2、照度會共用一個 STGCN 骨幹與時空特徵，最後在分成四個輸出頭產生不同預測結果。輸出頭是一小段專用的小型神經網路，處理邏輯就是假設有一個時空特徵 H_{shared} ，則溫度與濕度就會變成：

$$\hat{Y}_T = f_T(H_{\text{shared}}) \quad \hat{Y}_H = f_H(H_{\text{shared}})$$

訓練方法使用損失函數算誤差，然後合成總損失，其中 λ 代表各任務的重要程度。

$$\mathcal{L}_{\text{total}} = \lambda_T \mathcal{L}_T + \lambda_H \mathcal{L}_H + \lambda_C \mathcal{L}_C + \lambda_L \mathcal{L}_L$$

第八個是加入控制動作，這樣做是為了讓模型處理控制設備後的環境變化，設 s 為環境狀態， u 為空調、風扇、燈光、窗簾等動作，即

$$\hat{s}_{t+1:t+H} = f_{\theta}(s_{t-T+1:t}, u_{t:t+H-1})$$

模型就可以回答採取這組設備動作後，未來的環境會如何變化？

最後，流程會變成

感測資料 → 資料前處理 → 多尺度 TCN → 多關係動態 MR-STGCN → 多尺度 TCN → 物理殘差 → 多任務環境預測 → RL 決策 → 安全規則 → 設備控制 → 感測回饋

10.RL 強化學習

MR-STGCN 告訴系統未來可能發生什麼，但這樣難以處理一些複雜的人因問題，所以要搭配強化學習，根據現在與未來的環境狀態，選擇長期而言最舒適、最安全且最節能的設備控制動作。

學習狀態 s_t 包含：

$s_t = [\text{目前環境}, \text{未來環境預測}, \text{人數}, \text{設備狀態}, \text{時間資訊}]$

強化學習輸出的動作 a_t 為設備控制命令，比如以下陣列

$$a_t = [T_{\text{set}}, V_{\text{fresh}}, V_{\text{fan}}, P_{\text{dehumidifier}}, D_{\text{light}}, O_{\text{curtain}}]$$

一開始會將這個部分離散化(可能使用 DQN)，以降低訓練難度；後期再嘗試改用連續動作控制(PPO 或 SAC)。

還會需要一個獎勵函數，獎勵函數同時考量環境品質、能源消耗及設備穩定性，比如：

$$r_t = -(w_T P_T + w_H P_H + w_C P_C + w_L P_L + w_E P_E + w_S P_S)$$

P 指的是舒適度偏差或懲罰，比如 P_S 就是設備頻繁切換的懲罰，控制目標為最大化長期累積獎勵：

$$J = \mathbb{E} \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k} \right]$$

不過，強化學習不直接在真實建築中進行初期探索，而是利用歷史資料、簡化物理模型及神經網路建立模擬環境，可以理解成目前狀態 → RL 選擇動作 → 模擬環境計算下一狀態 → 計算獎勵 → 更新控制策略。另外 RL 的決策要先機過安全機制層，避免發生短暫的極端甚至致人於死地的判斷。